

Evaluación de impacto:

Tema 2

Francesco Bogliacino



OLS y Mean Independence

Primero una terminología

- Y: LHS, variable dependiente, outcome, variable explicada, variable predecida
- X: RHS, variable independiente, explicativa, control, predictor, regresor

1. ¿Cuál es la relación funcional entre x & y ?
2. ¿Cómo permitimos que otras variables aparte de x afecten y ?
3. ¿Cómo hacemos para identificar una relación *ceteris paribus*?

OLS

- La regresión lineal es un modelo sobre la **población**;

$$Y = \beta_0 + \beta_1 x + u$$

- para poder estimar β_0 y β_1 necesitamos caracterizar la relación entre x y u **en la población**

Supuestos

- Hacemos primero el supuesto que el valor esperado de u , que escribimos $E[u]=0$
- ¿Qué es el valor esperado? sería la media calculada sobre la población entera que es $\int u(i)p(u(i))di$ o $\sum u_i p(u_i)$
- Es un problema ese supuesto? NO, asuma que no sea cero sino α_0

Puedo redefinir $Y = (\beta_0 + \alpha_0) + \beta_1 x + (u - \alpha_0)$

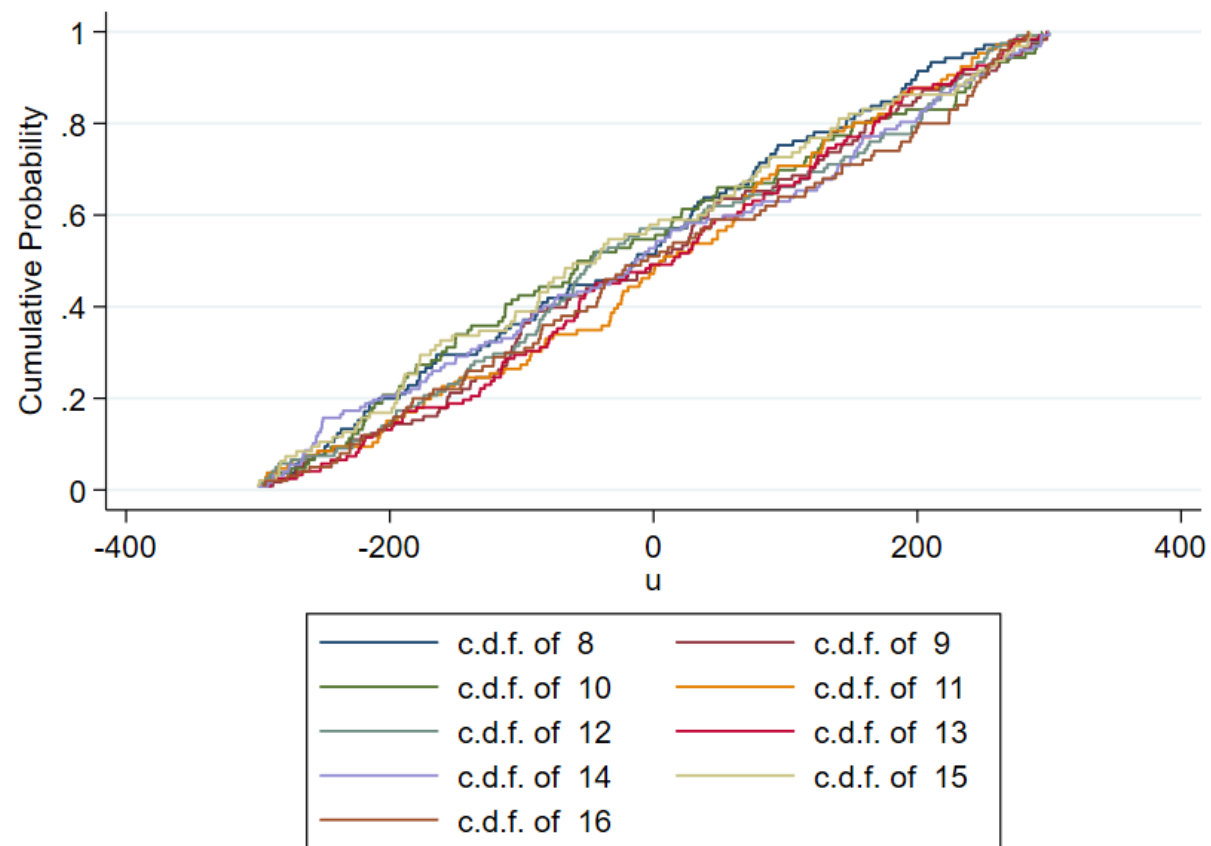
Supuestos

- Un supuesto clave (con el cual lidiaremos todo el curso) es este:
- $E[u|x] = E[u]$

	Altas habilidades blandas	Bajas habilidades blandas	
Graduado	0.16	0.14	0.30
No graduado	0.37	0.33	0.70
	0.53	0.47	

- $E[u] = 2 * 0.53 + 1 * 0.47 = 1.53$
- $E[u|G] = 2 * 0.53 + 1 * 0.47 = 1.53 = E[u|NG]$

	Altas habilidades blandas=2	Bajas habilidades blandas=1	
Graduado	$P(u=2 G)=0.16/0.3$ $0=0.53$	$P(u=1 G)=0.14/0.3$ $0=0.47$	0.30
No graduado	0.37	0.33	0.70
	0.53	0.47	



Mean independence

- Obviamente en muchos casos (ej educación) este es un mal supuesto;
- Este segundo supuesto es lo que llamamos independencia en promedio (mean Independence en inglés)

OLS


- La regresión lineal es un modelo sobre la **población**;

$$Y = \beta_0 + \beta_1 x + u$$


- Qué pasa con el supuesto de independencia en promedio?

$$E[Y|x] = \beta_0 + \beta_1 x + E[u|x] = \beta_0 + \beta_1 x$$

La CEF o PRF en práctica



El estimador



¿Cómo estimamos?

- Primero nosotros queremos “identificar” β_0, β_1 pero los “estimamos” porque no trabajamos con la población sino con una muestra $\{y_i, x_i\}$ y no observamos u_i ;
- El estimador nos dará un valor $\hat{\beta}$ que depende de la muestra, es decir a muestras diferentes sacaremos valores diferentes;
- Esta es la “variabilidad” de la muestra:
 - Piensen en Lalonde, el valor estaba alrededor de los 800 USD, pero muestras diferentes me dan valores diferentes
 - Quisiéramos pegarle en “promedio”

Algunas implicaciones de mean independence

- Si $E[\mathbf{u}|\mathbf{x}] = \mathbf{0}$ es obvio que $E[\mathbf{u}] = \mathbf{0}$
- Si $E[\mathbf{u}|\mathbf{x}] = \mathbf{0}$ es obvio que $\mathbf{Cov}(\mathbf{x}, \mathbf{u}) = E[\mathbf{x}\mathbf{u}] = \mathbf{0}$

Llamamos $x'_i, x''_i, \dots, x^n_i$ los valores que asume la variable x

- $\frac{1}{N} \sum_{i=1}^N x_i u_i = \frac{1}{N} [N' x'_i \left(\frac{1}{N'} \sum_{i=1}^{N'} u_i \right) + \dots + Nn x^n_i \left(\frac{1}{Nn} \sum_{i=1}^{Nn} u_i \right)]$
- Pero sabemos que todos esos promedios son ceros
- Noten que acabamos de hacer $E[\mathbf{x}\mathbf{u}] = E[\mathbf{x}E[\mathbf{u}|\mathbf{x}]]$ que tiene el nombre de Ley de Expectativas Iteradas

Algunas implicaciones de mean independence

- Si $E[u|x] = \mathbf{0}$ es obvio que $E[u] = E[y - \beta_0 + \beta_1 x] = \mathbf{0}$
- Si $E[u|x] = \mathbf{0}$ es obvio que $Cov(x, u) = E[x(y - \beta_0 - \beta_1 x)] = \mathbf{0}$
- En la muestra:
- $\frac{1}{N} \sum_{i=1}^N (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i) = 0$
- $\frac{1}{N} \sum_{i=1}^N x_i (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i) = 0$

Ahora lo que hay que hacer es resolver esas dos ecuaciones, en dos incognitas

Algunas implicaciones de mean independence

- $\frac{1}{N} \sum_{i=1}^N y_i - \widehat{\beta}_0 - \widehat{\beta}_1 \frac{1}{N} \sum_{i=1}^N x_i = 0 \rightarrow \widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}$

- $\frac{1}{N} \sum_{i=1}^N x_i (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i) = 0 \rightarrow$

$$\frac{1}{N} \sum_{i=1}^N x_i (y_i - [\bar{y} - \widehat{\beta}_1 \bar{x}] - \widehat{\beta}_1 x_i) = 0$$

$$\frac{1}{N} \sum_{i=1}^N x_i (y_i - \bar{y}) = \widehat{\beta}_1 \frac{1}{N} \sum_{i=1}^N x_i (x_i - \bar{x})$$

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \widehat{\beta}_1 \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

Algunas implicaciones de mean independence

- Si $\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 > 0$ entonces

$$\widehat{\beta}_1 = \frac{\text{covarianza.m}(x, y)}{\text{varianza.m}(x)}$$

OLS

- OLS es lo que acabamos de ver
- La lógica es que usamos la variabilidad en la muestra de x para poder identificar el impacto sobre y
- Pero ojo que:
 - Estamos USANDO un SUPUESTO sobre la población
 - Siempre podemos **calcular** OLS (a menos que X no varíe) pero no necesariamente **identificamos** el beta de la población
- Para calcular OLS en esta manera usamos condiciones sobre los MOMENTOS
- Una alternativa es la siguiente

OLS

- Define \hat{y}_i como la predicción. Puedo querer predecir el sueldo de la unidad i sabiendo su educación x_i
- $\hat{y}_i = \hat{\beta}_0 - \hat{\beta}_1 x_i$
- El error de predicción es $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$
- Definamos un criterio a minimizar,

$$\frac{1}{N} \sum_1^N \hat{u}_i^2$$

- Minimizando eso logramos exactamente lo mismo

OLS

- OJO! Los errores de predicción o residuales NO son los términos u_i que nunca observamos;
- Los residuales por construcción suman a cero

$$\frac{1}{N} \sum_{i=1}^N (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i) = 0$$

- Y por construcción $\frac{1}{N} \sum_{i=1}^N x_i (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i) = 0$ son ortogonales a x_i
- No usen la ortogonalidad de los residuales para inferir independencia de los u_i de x_i (si lo hacen me va a caer una lagrimita)

OLS


- Recuerden también que $\hat{y}_i = \hat{\beta}_0 - \hat{\beta}_1 x_i$
- $\frac{1}{N} \sum_{i=1}^N \hat{y}_i \hat{u}_i = \hat{\beta}_0 \frac{1}{N} \sum_{i=1}^N \hat{u}_i - \hat{\beta}_1 \frac{1}{N} \sum_{i=1}^N x_i \hat{u}_i = 0$
- Es decir las predicciones son ortogonales a los errores, y así cualquier función lineal
- Finalmente recuerden que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ o sea que si hago la predicción para el promedio saco el promedio. Esto es porque decidimos que así fuera



Resumen: propiedades algebraicas de OLS

- (\bar{x}, \bar{y}) está en la recta de regresión
 - Las predicciones y los residuales no están correlacionados
 - Los residuales y el predictor no están correlacionados
 - Los residuales suman a cero
-

OLS
y su valor
esperado



Tengamos presente el objetivo

- Nosotros observamos una muestra
- Quisiéramos decir algo sobre la población
- Vamos a ver como nos va con OLS en Stata

OLS

- Como ocurrió con el ejemplo simulado, OLS tiene variabilidad, cada muestra nos restituye un valor diferente que depende de la características de los datos
- En el ejemplo simulado, en promedio acertábamos, pero se ve una campana alrededor del valor verdadero;
- Vimos también que dada la varianza de los datos, la cantidad de observaciones y el efecto que queremos identificar, hay un cierto número de veces que nos equivocamos en una dirección o en la otra

Supuestos (1)

- El modelo para la población se puede escribir $Y = \beta_0 + \beta_1 x + u$
- Implicaciones: nuestros parámetros de interés son β_0, β_1
- Recuerden donde queremos ir: nosotros vamos a tener un modelo así por definición de Outcome Alternativos Potenciales
- \mathbf{X} y \mathbf{u} son realizaciones de variables aleatorias por lo tanto lo es \mathbf{y}
- Este supuesto es el de *linealidad en los parámetros*

Supuestos (2)

- El muestreo es aleatorio e independiente
- Para cada i podemos escribir $y_i = \beta_0 + \beta_1 x_i + u_i$
- Ojo que u_i es la componente no observable. No es el error de predicción

Supuestos (3): obvio

- Tenemos variabilidad en la x_i
- Esto en práctica es obvio, sin variabilidad en la x podemos cerrar todo e irnos

Supuestos (4)

- Este es el supuesto clave: la componente no observable tiene media condicional cero

$$E[u|x] = 0$$

Recuerden: yo (o Stata, o R) podemos calcular OLS que eso se cumpla o menos y de hecho independientemente hasta del supuesto 1

OLS es no sesgado

- Queremos mostrar que $E[\widehat{\beta}_1] = \beta_1$

$$\widehat{\beta}_1 = \frac{\sum_i (y_i - \bar{y})(x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

Llamemos $\sum_i (x_i - \bar{x})^2 = TOT_x$

Sabemos que $TOT_x > 0$ por el supuesto (3)

OLS es no sesgado

- Remplacemos (por supuesto 1 y 2) $y_i = \beta_0 + \beta_1 x_i + u_i$

$$\begin{aligned}\sum_i (y_i - \bar{y})(x_i - \bar{x}) &= \sum_i (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i) = \\ &\beta_0 \sum_i (x_i - \bar{x}) + \beta_1 \sum_i (x_i - \bar{x}) x_i + \sum_i (x_i - \bar{x}) u_i = \\ &\beta_1 TOT_x + \sum_i (x_i - \bar{x}) u_i\end{aligned}$$

$$\widehat{\beta_1} = \beta_1 + \frac{\sum_i (x_i - \bar{x}) u_i}{\sum_i (x_i - \bar{x})^2}$$

¿Qué es ese último término?

OLS es no sesgado

- Definan $w_i = \frac{x_i - \bar{x}}{\sum_i (x_i - \bar{x})^2}$
- Podemos escribir el último término como $\sum_i w_i u_i$
- recuerden que:
 - cada w_i es función de los x_i
 - El estimador es entonces función lineal de los términos no observables

OLS es no sesgado

- Vamos a usar el mismo trick que hemos aprendido

$$\begin{aligned} E[\widehat{\beta}_1] &= \beta_1 + E\left[\sum_i w_i u_i\right] = \\ \beta_1 + \sum_i E[w_i u_i] &= \beta_1 + \sum_i E[w_i E[u_i | x_i]] \end{aligned}$$

- Luego usamos el supuesto (4) y $E[\widehat{\beta}_1] = \beta_1$
- Es clave que en la población x y u no sean correlacionados o esto no ocurriría

Resumen

- Con los supuestos (1)-(4) OLS no es sesgado
- Problema: cada muestra nos dará un valor diferentes. En general nos concentramos cerca del valor del parámetro
- Nosotros podemos esperar que nuestra muestra sea “típica” pero no sabemos porque
- Recuerden también:
 - Los u_i no son observables, son las distancias de las observaciones respecto a la CEF o RPF
 - Los residuales son las distancias verticales entre las observaciones y la relación estimada. Eso si se observan (más precisamente se calculan)


W LINEAL

2

E

Back to CEF

- Trabajemos con una población finita, sueldo y educación, hay un número de estados del mundo $x_i = \{1, \dots, 16\}$ que son variables aleatorias
- $y_i = I(x_i = 1)n^{-1} \sum_i y_i^{\text{cuando tienen } 1} + \dots + I(x_i = 16)n^{-1} \sum_i y_i^{\text{cuando tienen } 16} + \text{algo}$
- En otras palabras puedo decir que una variable es la suma de dos componentes: lo que puedo predecir dado que está en el estado x_i más un algo que ya no depende [=es independiente] de x_i




Source: MHE, p. 24

Dos interpretaciones


- Una variable y_i la puedo “romper” en dos componentes:
 - Lo que me explica la x_i y lo que no me explica la x_i
- Una variable la puedo predecir de la siguiente manera:
 - Lo que me ayude a predecir x_i y lo que no me ayuda a predecir la x_i
- Esa primera componente es la CEF, la $E[y_i|x_i]$, por lo cual la relación en la población siempre es

$$y_i = E[y_i|x_i] + \varepsilon_i = CEF + \text{algo ortogonal}$$

Por qué Lineal es vida 😊



Por qué Lineal es vida 😊



Recuerden hacia siempre donde vamos

- Vamos a usar la Regresión Lineal en la población para escribir la CEF

$$E[Y|x] = \beta_0 + \beta_1 x$$

- Porque al final lo que nos interesa es la CEF (y como esa se conecta a nuestro caso específico donde la x_i toma los dos valores 1 y 0), no las características específicas del soporte de una variable
- Eso nos permite una cuantificación “sencilla” y “transparente” de los coeficientes, que no *depende* de otras variables

Dos formulas importantes



La anatomía de la regresión



La variable omitida

La anatomía de la regresión

- Supongamos que la educación sea tan buena como aleatoriamente asignada una vez tengamos en cuenta la discriminación por género y el estrato socio-económico
- Miremoslo en una base de datos (-> Stata)

¿Qué quiere decir?

- Cuando introducimos variables de control además de nuestra x_i estamos usando la variabilidad *que queda* después de “igualar” las personas en término de estas variables de control
- Por esto es importante:
 - No controlar por cualquier cosa, sino por variables que me ayuden en eliminar la selección

La variable omitida

- No controlar por una variable que explica la selección impide recuperar el valor del parámetro, en otras palabras no nos permite estimar sin sesgo -> hay algo más, aparte de la variabilidad de la muestra, que nos afecta
- Pensemos en la educación, y el hecho que la habilidad también cuente en la educación y en el mercado del trabajo
- Back to the data....

La variable omitida

- Se lo voy a derivar para un caso más sencillo

$$y_i = \beta_0 + \beta_1 S_i + \beta_2 A_i + u_i$$

¿Qué pasa si no observo A?

$$\begin{aligned}\widehat{\beta}_1 &= \frac{Cov(S_i, y_i)}{Var(S_i)} = \frac{E[S_i, (\beta_0 + \beta_1 S_i + \beta_2 A_i + u_i)] - E[S_i]E[\beta_0 + \beta_1 S_i + \beta_2 A_i + u_i]}{Var(S_i)} = \\ &= \frac{\beta_0 E[S_i] + \beta_1 E[S_i^2] + \beta_2 E[S_i A_i] + E[S_i u_i] - E[S_i]\beta_0 - \beta_1 E[S_i]^2 - \beta_2 E[S_i]E[A_i] + E[S_i]E[u_i]}{Var(S_i)} \\ &= \frac{\beta_1 Var[S_i^2] + \beta_2 Cov[S_i A_i] + Cov[S_i u_i]}{Var(S_i)} = \beta_1 + \frac{\beta_2 Cov[S_i A_i]}{Var(S_i)}\end{aligned}$$

La variable omitida

- Si $Cov[S_i A_i] > 0$ y A_i no la observo, yo puedo tener muchos datos, muy limpios y hacer un montón de regresiones pero nunca identificaré el efecto de la educación (a lo mejor se en qué dirección estoy sobre estimando)
- Esta va a ser la norma cuando trabajemos con datos observables
- Para poder identificar β_1 necesito una estrategia de identificación


¿Y la varianza?

Un último esfuerzo

heteroschedasticity

Figure 2.9

$\text{Var}(\text{wage}|\text{educ})$ increasing with educ .



Dependencia en los datos

- A veces hay dependencia en los datos, cuando las observaciones de un grupo (cluster) se “contaminan”
- Como nos va con ,rob -> back to Stata